

重庆大学计算机专业核心课程《机器学习》

第10章 降维与度量学习

授课教师：郑林江

大纲

□ k近邻学习

□ 多维缩放

□ 主成分分析


□ 流形学习

□ 度量学习

问题背景

- ✓ 现实任务中经常会遇到**样本特征很多**的情况。
- ✓ 这时一方面会出现数据稀疏、存储和计算开销较大的问题。
- ✓ 另一方面不同特征之间还可能存在着较强相关性，带来信息冗余。
- ✓ 但如果直接删除部分特征，又可能损失有用信息，因此需要研究如何在尽量保留信息的前提下降低维度。

Data Compression



假设有未知两个的特征： x_1 长度，用厘米表示； x_2 是用英寸表示同一物体的长度。而特征 x_1 和 x_2 都是基本的长度度量，其实只需要有一个特征表示就可以了，因此我们可以将数据减少到一维。

降维的作用


- 降低时间复杂度和空间复杂度
- 节省提取不必要特征的开销
- 去掉数据集中夹杂的噪声
- 较简单的模型在小数据集上有更强的鲁棒性
- 当数据能有较少的特征进行解释，可以更好的解释数据，使得可以提取知识。
- 实现数据可视化

例子



Lenna

数据降维



□ + **TSNE**算法(Hinton及其学生Ivdmaaten提出)

k近邻学习

k近邻学习的工作机制

□ **k近邻(k-Nearest Neighbor, kNN)学习是一种常用的监督学习方法：**

- 确定训练样本，以及某种距离度量。
- 对于某个给定的测试样本，找到训练集中距离最近的k个样本，对于分类问题使用“投票法”获得预测结果，对于回归问题使用“平均法”获得预测结果。还可基于距离远近进行加权平均或加权投票，距离越近的样本权重越大。
 - **投票法：**选择这k个样本中出现最多的类别标记作为预测结果。
 - **平均法：**将这k个样本的实值输出标记的平均值作为预测结果。

“懒惰学习”与“急切学习”

K近邻学习没有显式的训练过程，属于“懒惰学习”

- “懒惰学习” (lazy learning): 此类学习技术在训练阶段仅仅是把样本保存起来，训练时间开销为零，待收到测试样本后再进行处理。
- “急切学习” (eager learning): 在训练阶段就对样本进行学习处理的方法。

k近邻分类示意图

□ k 近邻分类器中：

- k 是一个重要参数，当 k 取不同值时，分类结果会有显著不同。
- 另一方面，若采用不同的距离计算方式，则找出的“近邻”可能有显著差别，从而也会导致分类结果有显著不同。




图 10.1 k 近邻分类器示意图. 虚线显示出等距线; 测试样本在 $k=1$ 或 $k=5$ 时被判别为正例, $k=3$ 时被判别为反例.

k近邻学习

分析1NN二分类错误率 $P(err)$

- 暂且假设距离计算是“恰当”的，即能够恰当地找出k个近邻，我们来对“最近邻分类器”（1NN，即k=1）在二分类问题上的性能做一个简单的讨论。
- 给定测试样本 $\mathbf{x}$ ，若其最近邻样本为 $\mathbf{z}$ ，则最近邻出错的概率就是 $\mathbf{x}$ 与 $\mathbf{z}$ 类别标记不同的概率，即

$$P(err) = 1 - \sum_{c \in y} P(c|\mathbf{x})P(c|\mathbf{z})$$

k近邻学习

分析1NN二分类错误率 $P(err)$

□ 假设样本独立同分布，且对任意 $\mathbf{x}$ 和任意小正整数 δ ，在 $\mathbf{x}$ 附近 δ 距离范围内总能找到一个训练样本；换言之，对任意测试样本，总能在任意近的范围找到中的训练样本 $\mathbf{z}$ 。

□ 令 $c^* = \arg \max_{c \in \mathcal{Y}} P(c|\mathbf{x})$ 表示贝叶斯最优分类器的结果，有

$$\begin{aligned} P(err) &= 1 - \sum_{c \in \mathcal{Y}} P(c|\mathbf{x})P(c|\mathbf{z}) \\ &\simeq 1 - \sum_{c \in \mathcal{Y}} P^2(c|\mathbf{x}) \\ &\leq 1 - P^2(c^*|\mathbf{x}) \\ &= (1 + P(c^*|\mathbf{x}))(1 - P(c^*|\mathbf{x})) \\ &\leq 2 \times (1 - P(c^*|\mathbf{x})) . \end{aligned}$$

□ 惊讶发现：最近邻分类虽简单，但它的泛化错误率不超过贝叶斯最优分类器错误率的两倍！

低维嵌入

维数灾难 (curse of dimensionality)

- 上述讨论基于一个重要的假设：任意测试样本 $\mathbf{x}$ 附近的任意小的 δ 距离范围内总能找到一个训练样本，即训练样本的采样密度足够大，或称为“密采样”。然而，这个假设在现实任务中通常很难满足。
- 事实上，在高维情形下出现的数据样本稀疏、距离计算困难等问题，是所有机器学习方法共同面临的严重障碍，被称为“维数灾难”。
- 虽然训练样本在形式上是高维的，但与学习任务真正相关的信息，也许只是高维空间中的某种低维嵌入。
- 如果能够找到这样的低维结构，就可以在保留主要信息的同时减少特征维数。

低维嵌入

- 缓解维数灾难的一个重要途径是降维(dimension reduction)
 - 即通过某种数学变换，将原始高维属性空间转变为一个低维“子空间”(subspace)，在这个子空间中样本密度大幅度提高，距离计算也变得更为容易。
- 为什么能进行降维？
 - 数据样本虽然是高维的，但与学习任务密切相关的也许仅是某个低维分布，即高维空间中的一个低维“嵌入”(embedding)，因而可以对数据进行有效的降维。




图 10.2 低维嵌入示意图



矩阵基础-特征值与特征向量

- 对于给定矩阵 A ，寻找一个常数 λ （可以为复数）和非零向量 x ，使得向量 x 被矩阵 A 作用后所得的向量 Ax 与原向量 x 平行，并且满足 $Ax = \lambda x$ 。
- 设 A 是 n 阶方阵，若存在 n 维非零向量 x ，使

$$Ax = \lambda x$$

则称 λ 为 A 的特征值， x 为 A 属于 λ 的特征向量。

矩阵基础-特征值与特征向量




矩阵基础-特征值与特征向量

特征空间包括所有特征向量

$$A\vec{v} = \lambda\vec{v}$$

特征值

特征向量



如果把矩阵看作是运动，那么特征值就是运动的速度，特征向量就是运动的方向。

矩阵基础-特征值与特征向量

- 从几何角度看，矩阵可以理解为对向量进行线性变换。
- 大多数向量在变换后方向和长度都会变化，而特征向量比较特殊：它在变换后方向保持不变，只发生伸缩，这个伸缩比例就是特征值。
- 因此，特征值分解能够帮助我们找出矩阵最主要的变化方向。

矩阵基础-特征值与特征向量

- 看出一个矩阵和一个向量相乘的意义在于对该向量做旋转或伸缩变换。
- 一个矩阵和该矩阵的非特征向量相乘是对该向量的旋转变换；一个矩阵和该矩阵的特征向量相乘是对该向量的伸缩变换。
- 一个实数和一个向量相乘有什么意义呢？是对一个向量的伸缩变换。
- 一个矩阵和一个向量相乘与一个实数和一个向量相乘的联系找到了----“对该向量伸缩变换”。
- 通过以上分析，特征向量就是一个在矩阵 A 的变换下没有旋转只是伸缩变换，那到底伸缩了多少倍呢？——伸缩了“特征值”倍。

矩阵基础-矩阵的迹trace

□ 矩阵的迹是对角线上元素之和

对于方阵 $A = \begin{bmatrix} a_{11} & \cdots & a_{1n} \\ \vdots & \ddots & \vdots \\ a_{n1} & \cdots & a_{nn} \end{bmatrix}$

$$\text{tr}A = \sum_{i=1}^n a_{ii}$$

四个主要性质:

① $\text{tr}A = \text{tr}A^T$

② $\text{tr}AB = \text{tr}BA$

③ $\nabla_A \text{tr}AB = B^T$

④ $\nabla_A \text{tr}ABA^T C = CAB + C^T AB^T$

矩阵基础-特征值分解

- 一个矩阵的一组特征向量是一组正交向量。特征值分解是将一个矩阵分解成下面的形式（缩放矩阵+特征向量矩阵）：

$$A = Q \Sigma Q^{-1}$$

- 其中Q是这个矩阵A的特征向量组成的矩阵， Σ 是一个对角阵，每一个对角线上的元素就是一个特征值。一个矩阵其实就是一个线性变换。比如说下面的一个矩阵：

$$M = \begin{bmatrix} 3 & 0 \\ 0 & 1 \end{bmatrix}^{-1}$$


- 其实对应的线性变换是下面的形式：

矩阵基础-特征值分解


- 对称矩阵：变换是一个对x，y轴的方向一个拉伸变换（每一个对角线上的元素将会对一个维度进行拉伸变换，当值 >1 时，是拉长，当值 <1 时是缩短）

$$M = \begin{bmatrix} 3 & 0 \\ 0 & 1 \end{bmatrix}$$

$$\begin{bmatrix} 3 & 0 \\ 0 & 1 \end{bmatrix} \begin{bmatrix} x \\ y \end{bmatrix} = \begin{bmatrix} 3x \\ y \end{bmatrix}$$




M
→




矩阵基础-特征值分解

□ 当矩阵不是对称的时候，假如说矩阵是下面：

$$M = \begin{bmatrix} 1 & 1 \\ 0 & 1 \end{bmatrix}$$



M
→



矩阵基础-特征值分解

- 这其实是在平面上对一个轴进行的拉伸变换（如蓝色的箭头所示），在图中，蓝色的箭头是一个最主要的变化方向（变化方向可能有不止一个）。
- 特征值分解的式子解得到的 Σ 矩阵是一个对角阵，里面的特征值是由大到小排列的，这些特征值所对应的特征向量就是描述这个矩阵变化方向（从主要的变化到次要的变化排列）
- 当矩阵是高维的情况下，那么这个矩阵就是高维空间下的一个线性变换，通过特征值分解得到的前 N 个特征向量，那么就对应了这个矩阵最主要的 N 个变化方向。利用这前 N 个变化方向，就可以近似这个矩阵（变换）。也就是之前说的：提取这个矩阵最重要的特征。

矩阵基础-特征值分解

- 总结一下，特征值分解可以得到特征值与特征向量，特征值表示的是这个特征到底有多重要，而特征向量表示这个特征是什么，可以将每一个特征向量理解为一个线性的子空间，可以利用这些线性的子空间干很多的事情。不过，特征值分解也有很多的局限，比如说变换的矩阵必须是方阵。
- 特征值反映了对应方向的重要程度，特征向量给出了这些方向本身。不过，特征值分解要求矩阵必须是方阵，因此在更一般的情形下，常使用奇异值分解（SVD）来处理。

大纲

□ k近邻学习

□ 多维缩放

□ 主成分分析

□ 流形学习

□ 度量学习

多维缩放

- 若要求原始空间中样本之间的距离在低维空间中得以保持，即得到“**多维缩放**” (Multiple Dimensional Scaling, MDS)
- 考虑一个这样的问题。有 n 个样本，每个样本维度为 m 。目标是用不同的新的 k 维向量 ($k \ll m$) 替代原来的 n 个 m 维向量，使得在新的低维空间中，所有样本相互之间的距离**等于**（或**最大程度接近**）原空间中的距离（默认欧氏距离）。
- 例如：原有3个4维样本 $(1,0,0,3), (8,0,0,5), (2,0,0,4)$ ，显然可以用三个新的二维样本 $(1,3), (8,5), (2,4)$ 来保持维度变小并相互之间距离不变。
- 如果不是这么明显的数据该如何来处理？降维后的距离一定会相等吗？**多维缩放MDS算法**给出了在给定 k 值条件下的最优解决方案。

多维缩放

- 假定有 m 个样本，在原始空间中的距离矩阵为 $D \in \mathbb{R}^{m \times m}$ ，其第 i 行 j 列的元素 $dist_{ij}$ 为样本 x_i 到 x_j 的距离。
- 目标是获得样本在 d' 维空间的表示 $Z \in \mathbb{R}^{d' \times m}$ 且任意两个样本在 d' 维空间的欧氏距离等于原始空间中的距离，即 $\|z_i - z_j\| = dist_{ij}$ 。
- 令 $B = Z^T Z \in \mathbb{R}^{m \times m}$ ，其中 B 为降维后的内积矩阵， $b_{ij} = z_i^T z_j$ ，有

$$dist_{ij}^2 = \|z_i\|^2 + \|z_j\|^2 - 2z_i^T z_j = b_{ii} + b_{jj} - 2b_{ij}。$$




图 10.2 低维嵌入示意图

多维缩放

- 为便于讨论，令降维后的样本 $\mathbf{Z}$ 被中心化，即 $\sum_{i=1}^m \mathbf{z}_i = \mathbf{0}$ 。显然，矩阵 $\mathbf{B}$ 的行与列之和均为零，即

$$\sum_{i=1}^m b_{ij} = \sum_{j=1}^m b_{ij} = 0$$

易知 $\sum_{i=1}^m \text{dist}_{ij}^2 = \text{tr}(\mathbf{B}) + m b_{jj}$,

$$\sum_{j=1}^m \text{dist}_{ij}^2 = \text{tr}(\mathbf{B}) + m b_{ii},$$

$$\sum_{i=1}^m \sum_{j=1}^m \text{dist}_{ij}^2 = 2m \text{tr}(\mathbf{B})$$

其中 $\text{tr}(\cdot)$ 表示矩阵的迹(trace), $\text{tr}(\mathbf{B}) = \sum_{i=1}^m \|\mathbf{z}_i\|^2$ 。

多维缩放

令

$$\sum_{i=1}^m dist_{i.}^2 = tr(B) + m b_{jj},$$

$$\sum_{j=1}^m dist_{.j}^2 = tr(B) + m b_{ii},$$

$$\sum_{i=1}^m \sum_{j=1}^m dist_{ij}^2 = \frac{1}{m^2} \sum_{i=1}^m \sum_{j=1}^m dist_{ij}^2$$

由此即可通过降维前后保持不变的距离矩阵 D 求取内积矩阵 B :

$$b_{ij} = -\frac{1}{2} (dist_{ij}^2 - dist_{i.}^2 - dist_{.j}^2 + dist_{..}^2)$$

多维缩放

□ 对矩阵 B 做特征值分解(eigenvalue decomposition) $B = V\Lambda V^T$, 其中 $\Lambda = \text{diag}(\lambda_1, \lambda_2, \dots, \lambda_d)$ 为特征值构成的对角矩阵,

$\lambda_1 \geq \lambda_2 \geq \dots \geq \lambda_d$ 为特征向量矩阵, 假定其中有 d^* 个非零特征值, 它们构成对角矩阵 $\Lambda_* =$

$\text{diag}(\lambda_1, \lambda_2, \dots, \lambda_{d_*})$, V 为特征向量矩阵。令 V_* 表示相应的特征矩阵, 则 Z 可表达为 $Z = \Lambda_*^{\frac{1}{2}} V_*^T \in \mathbb{R}^{d^* \times m}$ 。

□ 在现实应用中为了有效降维, 往往仅需降维后的距离与原始空间中的距离尽可能接近, 而不必严格相等。此时可取 $d' \ll d$ 个最大特征值构成对角矩阵 $\tilde{\Lambda} = \text{diag}(\lambda_1, \lambda_2, \dots, \lambda_{d'})$, 令 $\tilde{V}$ 表示相应的特征向量矩阵, 则 Z 可表达为 $Z = \tilde{\Lambda}^{1/2} \tilde{V}^T \in \mathbb{R}^{d' \times m}$ 。

MDS算法的描述

输入：距离矩阵 $\mathbf{D} \in \mathbb{R}^{m \times m}$, 其元素 $dist_{ij}$ 为样本 $\mathbf{x}_i$ 到 $\mathbf{x}_j$ 的距离;
低维空间维数 d' .

过程:

- 1: 根据式(10.7)–(10.9)计算 $dist_{i.}^2, dist_{.j}^2, dist_{..}^2$;
- 2: 根据式(10.10)计算矩阵 $\mathbf{B}$;
- 3: 对矩阵 $\mathbf{B}$ 做特征值分解;
- 4: 取 $\tilde{\mathbf{\Lambda}}$ 为 d' 个最大特征值所构成的对角矩阵, $\tilde{\mathbf{V}}$ 为相应的特征向量矩阵.

输出：矩阵 $\tilde{\mathbf{V}}\tilde{\mathbf{\Lambda}}^{1/2} \in \mathbb{R}^{m \times d'}$, 每行是一个样本的低维坐标

图 10.3 MDS 算法

线性降维方法

- 一般来说，欲获得低维子空间，最简单的是对原始高维空间进行线性变换。给定 d 维空间中的样本 $X = (x_1, x_2, \dots, x_m) \in \mathbb{R}^{d \times m}$ ，变换之后得到 $d' \leq d$ 维空间中的样本

$$Z = W^T X$$

其中 $W \in \mathbb{R}^{d \times d'}$ 是变换矩阵， $Z \in \mathbb{R}^{d' \times m}$ 是样本在新空间中的表达。

- 变换矩阵 W 可视为 d' 个 d 维属性基向量。换言之， z_i 是原属性向量 x_i 在新坐标系 $\{w_1, w_2, \dots, w_{d'}\}$ 中的坐标向量。若 w_i 与 $w_j (i \neq j)$ 正交，则新坐标系是一个正交坐标系，此时 W 为正交变换。显然，新空间中的属性是原空间中的属性的线性组合。
- 基于线性变换来进行降维的方法称为线性降维方法，对低维子空间性质的不同要求可通过对 W 施加不同的约束来实现。

大纲

- k近邻学习
- 多维缩放
- 主成分分析
- 流形学习
- 度量学习

PCA主成分分析

- PCA (Principal Component Analysis) 是一种常用的数据分析方法。PCA通过线性变换将原始数据变换为一组各维度线性无关的表示，可用于提取数据的主要特征分量，**常用于高维数据的降维**。
- 例如某淘宝店2018年全年的流量及交易情况可以看成一组记录的集合，其中每一天的数据是一条记录，格式如下：
(日期, 浏览量, 访客数, 下单数, 成交数, 成交金额)

- 其中“日期”是一个记录标志而非度量值，而数据挖掘关心的大多是度量值，因此忽略日期这个字段后，得到一组记录，每条记录可以被表示为一个五维向量：

$$(500, 240, 25, 13, 2312.15)^T$$

- 当然可以对这一组五维向量进行分析和挖掘，但是很多机器学习算法的复杂度和数据的维数有着密切关系，甚至与维数呈指数级关联。当维数成百上千时，数据挖掘的资源消耗是不可接受的，因此必须对数据进行降维。
- 降维当然意味着信息的丢失，不过鉴于实际数据本身常常存在的相关性，可以想办法在降维的同时将信息的损失尽量降低。

PCA

- 例如某学籍数据有两列M和F，其中M列的取值是如果此学生为男性取值1，为女性取值0；而F列是学生为女性取值1，男性取值0。此时如果统计全部学籍数据，会发现对于任何一条记录来说，当M为1时F必定为0，反之当M为0时F必定为1。在这种情况下，将M或F去掉实际上没有任何信息的损失，因为只要保留一列就可以完全还原另一列。
- 当然上面是一个极端的情况，在现实中也许不会出现，**不过类似的情况还是很常见**。例如上面淘宝店铺的数据中“浏览量”和“访客数”往往具有较强的**相关关系**，而“下单数”和“成交数”也具有较强的相关关系。这里“相关关系”可以直观理解为“当某一天这个店铺的浏览量较高（或较低）时，应该很大程度上认为这天的访客数也较高（或较低）”。


PCA

- 上面给出的是降维的朴素思想描述，可以有助于直观理解降维的动机和可行性，但并不具有操作指导意义。例如，怎样的投影方向才算“最好”？如何在降维以后尽量保留原始数据中的主要信息？PCA 正是围绕这些问题，给出了一套清晰的数学解决方案。
- 要回答上面的问题，就要对降维问题进行数学化和形式化的讨论。而**PCA是一种具有严格数学基础并且已被广泛采用的降维方法。**

PCA主成分分析


直观理解:身高与体重

- 假设我们正在构建一个健康风险预测模型，数据集中有身高和体重两个特征：
 - ✓ 身高越高的人，体重往往也越重。
 - ✓ 数据点大致沿着从左下到右上的对角线排列。
- 这两个特征之间存在强烈的正相关关系，携带着重叠的信息。



直观理解:寻找最佳代表方向

- PCA会找到那条最能代表数据走势的对角线方向，然后把所有数据点都投影到这条线上。
- ✓ 投影之后，每个人只需要一个数值就能表示他的位置(从2维降到1维)
- ✓ 这个新特征非常近似于医学上熟知的概念：**BMI**(体重指数)!



PCA在不知道医学知识的情况下，纯粹从数据的数学结构出发自动发现了这个组合特征。

PCA的数学原理


□ 方差(Variance)

- 每个数减去均值，平方后再平均。
- 数据越分散，方差越大。

□ 协方差(Covariance)

- 两个变量各自减去均值后相乘再平均。
- 正负反映两个变量是否同步变化。

PCA的底层逻辑建立在协方差矩阵和特征值分解之上。假设我们有一个包含 n 个样本、 d 个特征的数据集矩阵 X (大小为 $n*d$)，将其降维到 k 维。



内积与投影

□ 向量运算：内积。两个维数相同的向量的内积被定义为：

$$(a_1, a_2, \dots, a_n)^T \cdot (b_1, b_2, \dots, b_n)^T = a_1 b_1 + a_2 b_2 + \dots + a_n b_n$$


□ 内积运算将两个向量映射为一个实数。下面分析内积的几何意义。假设A和B是两个n维向量，n维向量可以等价表示为n维空间中的一条从原点发射的有向线段，假设A和B均为二维向量，则 $A=(x_1, y_1)$ ， $B=(x_2, y_2)$ 。则在二维平面上A和B可以用两条发自原点的有向线段表示，见下图：

内积与投影

□ 从A点向B所在直线引一条垂线。垂线与B的交点叫做A在B上的投影，再设A与B的夹角是 a ，则投影的矢量长度为 $|A| \cos(a)$ ，向量A的模，也就是A线段的标量长度为： $|A| = \sqrt{x_1^2 + y_1^2}$

□ 要区分矢量长度和标量长度，标量长度总是大于等于0，值就是线段的长度；而矢量长度可能为负，其绝对值是线段长度，而符号取决于其方向与标准方向相同或相反。

□ 如果将内积表示为另一种形式： $A \cdot B = |A||B| \cos(\alpha)$



内积与投影


- 进一步假设B的模为1，即让 $|B|=1$ ，那么就变成了

$$A \cdot B = |A| \cos(\alpha)$$

- 设向量B的模为1，则A与B的内积值等于A向B所在直线投影的矢量长度！这就是内积的一种几何解释，也是一个重要结论。


基

- 一个二维向量可以对应二维笛卡尔直角坐标系中从原点出发的一个有向线段
- 在代数表示方面，经常用线段终点的点坐标表示向量，例如上面的向量可以表示为 $(3, 2)$ 。不过只有一个 $(3, 2)$ 本身是不能够精确表示一个向量的。这里的3实际表示的是向量在x轴上的投影值是3，在y轴上的投影值是2。也就是说其实隐式引入了一个定义：以x轴和y轴上正方向长度为1的向量为标准。
- 更正式的说，向量 (x, y) 实际上表示线性组合： $x(1,0)^T + y(0,1)^T$



基

- 不难证明所有二维向量都可以表示为这样的线性组合。此处 $(1, 0)$ 和 $(0, 1)$ 叫做二维空间中的一组基。所以，要准确描述向量，首先要确定一组基，然后给出在基所在的各个直线上的投影值。只不过经常省略第一步，而默认以 $(1, 0)$ 和 $(0, 1)$ 为基。
- 一般来说，希望基的模是1，因为从内积的意义可以方便的用向量点乘基而直接获得其在新基上的坐标。实际上，对应任何一个向量总可以找到其同方向上模为1的向量，只要让两个分量分别除以模就好了。例如，上面的基可以变为 $(\frac{1}{\sqrt{2}}, \frac{1}{\sqrt{2}})$ 和 $(-\frac{1}{\sqrt{2}}, \frac{1}{\sqrt{2}})$ 。




基

□ 现在想获得 $(3, 2)$ 在新基上的坐标，即在两个方向上的投影矢量值，那么根据内积的几何意义，只要分别计算 $(3, 2)$ 和两个基的内积，不难得到新的坐标为 $(\frac{5}{\sqrt{2}}, -\frac{1}{\sqrt{2}})$ 。

□ 右图给出了新的基以及 $(3, 2)$ 在新基上坐标值的图：

□ 要注意的是，例子中基是正交的（即内积为0，或直观说相互垂直），但可以成为一组基的唯一要求就是线性无关，非正交的基也是可以的。



基变换的矩阵表示

□ 下面用矩阵相乘的形式来表示基变换：
$$\begin{pmatrix} \frac{1}{\sqrt{2}} & \frac{1}{\sqrt{2}} \\ -\frac{1}{\sqrt{2}} & \frac{1}{\sqrt{2}} \end{pmatrix} \begin{pmatrix} 3 \\ 2 \end{pmatrix} = \begin{pmatrix} \frac{5}{\sqrt{2}} \\ -\frac{1}{\sqrt{2}} \end{pmatrix}$$

□ 其中矩阵的两行分别为两个基，乘以原向量，其结果刚好为新基下的坐标。

□ 可以稍微推广一下，如果有m个二维向量，只要将二维向量按列排成一个两行m列矩阵，然后用“基矩阵”乘以这个矩阵，就得到了所有这些向量在新基下的值。

例如(1, 1), (2, 2), (3, 3)，想变换到刚才那组基上，则可以这样表示：

$$\begin{pmatrix} \frac{1}{\sqrt{2}} & \frac{1}{\sqrt{2}} \\ -\frac{1}{\sqrt{2}} & \frac{1}{\sqrt{2}} \end{pmatrix} \begin{pmatrix} 1 & 2 & 3 \\ 1 & 2 & 3 \end{pmatrix} = \begin{pmatrix} \frac{2}{\sqrt{2}} & \frac{4}{\sqrt{2}} & \frac{6}{\sqrt{2}} \\ 0 & 0 & 0 \end{pmatrix}$$

□ 于是一组向量的基变换被干净的表示为矩阵的相乘。

基变换的矩阵表示

- 一般的，如果有M个N维向量，想将其变换为由R个N维向量表示的新空间中，那么首先将R个基按行组成矩阵A，然后将向量按列组成矩阵B，那么两矩阵的乘积AB就是变换结果，其中AB的第m列为A中第m列变换后的结果。数学表示为：

$$\begin{pmatrix} p_1 \\ p_2 \\ \vdots \\ p_R \end{pmatrix} (a_1, a_2, \dots, a_M) = \begin{pmatrix} p_1 a_1 & \cdots & p_1 a_M \\ \vdots & \ddots & \vdots \\ p_R a_1 & \cdots & p_R a_M \end{pmatrix}$$

- 其中 p_i 是一个行向量，表示第i个基， a_j 是一个列向量，表示第j个原始数据记录。
- 特别要注意的是，R可以小于N，而R决定了变换后数据的维数。矩阵相乘的一种物理解释：**两个矩阵相乘的意义是将右边矩阵中的每一列列向量变换到左边矩阵中每一行行向量为基所表示的空间中去。**更抽象的说，一个矩阵可以表示一种线性变换。

协方差矩阵及优化目标

- 上面讨论了选择不同的基可以对同样一组数据给出不同的表示，而且如果基的数量少于向量本身的维数，则可以达到降维的效果。但是还没有回答一个最最关键的问题：**如何选择基才是最优的**。或者说，如果有一组N维向量，**现在要将其降到K维（K小于N），那么应该如何选择K个基才能最大程度保留原有的信息？**
- 为了避免过于抽象的讨论，以一个具体的例子展开。假设数据由五条记录组成，将它们表示成矩阵形式：

$$\begin{pmatrix} 1 & 1 & 2 & 4 & 2 \\ 1 & 3 & 3 & 4 & 4 \end{pmatrix}$$


协方差矩阵及优化目标

□ 其中每一列为一条数据记录，而一行为一个字段。为了后续处理方便，首先将每个字段内所有值都减去字段均值，其结果是将每个字段都变为均值为0（这样做的道理和好处后面会看到）。

□ 上面的数据，第一个字段均值为2，第二个字段均值为3，所以变换后：

$$\begin{pmatrix} -1 & -1 & 0 & 2 & 0 \\ -2 & 0 & 0 & 1 & 1 \end{pmatrix}$$

□ 五条数据在平面直角坐标系内的样子：



问题

- 在降维时，仅仅要求投影后的方差尽可能大还不够，还希望不同投影方向之间尽量不要表达重复的信息。
- 以上图为例，可以看出如果向x轴投影，那么最左边的两个点会重叠在一起，中间的两个点也会重叠在一起，于是本身四个各不相同的二维点投影后只剩下两个不同的值了，这是一种严重的信息丢失，
- 同理，如果向y轴投影最上面的两个点和分布在x轴上的两个点也会重叠。所以看来x和y轴都不是最好的投影选择。直观目测，如果向通过第一象限和第三象限的斜线投影，则五个点在投影后还是可以区分的。下面，用数学方法表述这个问题。

方差

- 希望投影后投影值尽可能分散，而这种分散程度，可以用数学上的方差来表述。

此处，一个字段的方差可以看做是每个元素与字段均值的差的平方和的均值，即：

$$Var(a) = \frac{1}{m} \sum_{i=1}^m (a_i - \mu)^2$$

- 由于上面已经将每个字段的均值都化为0，因此方差可以直接用每个元素的平方和除以元素个数表示：

$$Var(a) = \frac{1}{m} \sum_{i=1}^m a_i^2$$

- 于是上面的问题被形式化表述为：寻找一个一维基，使得所有数据变换为这个基上的坐标表示后，方差值最大。

协方差

- 对于上面二维降成一维的问题，找到那个使得方差最大的方向就可以了。同样的遇到三维降到二维问题：与之前相同，首先希望找到一个方向使得投影后方差最大，这样就完成了第一个方向的选择，继而选择第二个投影方向。
- 让两个字段尽可能表示更多的原始信息，是不希望它们之间存在（线性）相关性的，因为相关性意味着两个字段不是完全独立，必然存在重复表示的信息。
- 数学上可以用两个字段的协方差表示其相关性，由于已经让每个字段均值为0，则：

$$Cov(a, b) = \frac{1}{m} \sum_{i=1}^m a_i b_i$$

- 可以看到，在字段均值为0的情况下，两个字段的协方差简洁的表示为其内积除以元素数m。

协方差

- 当协方差为0时，表示两个字段完全独立。为了让协方差为0，选择第二个基时只能在与第一个基正交的方向上选择。因此最终选择的两个方向一定是正交的。
- 至此，得到了降维问题的优化目标：将一组N维向量降为K维（K大于0，小于N），其目标是选择K个单位（模为1）正交基，使得原始数据变换到这组基上后，各字段两两间协方差为0，而字段的方差则尽可能大（在正交的约束下，取最大的K个方差）。

协方差矩阵

□ 假设只有a和b两个字段，那么将它们按行组成矩阵X： $X = \begin{pmatrix} a_1 & a_2 & \cdots & a_m \\ b_1 & b_2 & \cdots & b_m \end{pmatrix}$

□ 然后用X乘以X的转置，并乘上系数1/m： $\frac{1}{m}XX^T = \begin{pmatrix} \frac{1}{m}\sum_{i=1}^m a_i^2 & \frac{1}{m}\sum_{i=1}^m a_i b_i \\ \frac{1}{m}\sum_{i=1}^m a_i b_i & \frac{1}{m}\sum_{i=1}^m b_i^2 \end{pmatrix}$

□ 奇迹出现了！这个矩阵对角线上的两个元素分别是两个字段的方差，而其它元素是a和b的协方差。

□ 根据矩阵相乘的运算法则，这个结论很容易被推广到一般情况：设有m个n维数据记录，将其按列排成n乘m的矩阵X，设： $C = \frac{1}{m}XX^T$

□ 则C是一个对称矩阵，其对角线分别个各个字段的方差，而第i行j列和j行i列元素相同，表示i和j两个字段的协方差。

协方差矩阵对角化

- 根据上述推导，等价于将协方差矩阵对角化：即除对角线外的其它元素化为0，并且在对角线上将元素按大小从上到下排列，这样就达到了优化目的。进一步看下原矩阵与基变换后矩阵协方差矩阵的关系：
- 设原始数据矩阵X对应的协方差矩阵为C，而P是一组基按行组成的矩阵，设Y=PX，则Y为X对P做基变换后的数据。设Y的协方差矩阵为D，推导一下D与C的关系：

$$D = \frac{1}{m}YY^T = \frac{1}{m}(PX)(PX)^T = \frac{1}{m}PXX^TP^T = P\left(\frac{1}{m}XX^T\right)P^T = PCP^T$$

- 优化目标变成：寻找一个矩阵P，满足PCP^T是一个对角矩阵，并且对角元素按从大到小依次排列，那么P的前K行就是要寻找的基，用P的前K行组成的矩阵乘以X就使得X从N维降到了K维并满足上述优化条件。

协方差矩阵对角化

□ 由上文知道，协方差矩阵C是一个是对称矩阵，在线性代数上，实对称矩阵有一系列非常好的性质：

1) 实对称矩阵不同特征值对应的特征向量必然正交。

2) 设特征向量 λ 重数为r，则必然存在r个线性无关的特征向量对应于 λ ，因此可以将这r个特征向量单位正交化。

□ 由上面两条可知，一个n行n列的实对称矩阵一定可以找到n个单位正交特征向量，设这n个特征向量为 $e_1, e_2, \dots, e_n$

□ 将其按列组成矩阵： $E = (e_1 \ e_2 \ \cdots \ e_n)$

协方差矩阵对角化

□ 则对协方差矩阵C有如下结论：

$$E^T C E = \Lambda = \begin{pmatrix} \lambda_1 & & & \\ & \lambda_2 & & \\ & & \ddots & \\ & & & \lambda_n \end{pmatrix}$$

□ 其中 Λ 为对角矩阵，其对角元素为各特征向量对应的特征值

协方差矩阵对角化

□ 已经找到了需要的矩阵P:

$$P = E^T$$

□ P是协方差矩阵的特征向量单位化后按行排列出的矩阵，其中每一行都是C的一个特征向量。如果设P按照 Λ 中特征值的从大到小，将特征向量从上到下排列，则用P的前K行组成的矩阵乘以原始数据矩阵X，就得到了降维后的数据矩阵Y。

□ 至此完成了整个PCA的数学原理讨论。在下面的一节，将给出PCA的一个实例。

PCA算法步骤

□ 设有 m 条 n 维数据。

1. 将原始数据按列组成 n 行 m 列矩阵 X
2. 将 X 的每一行（代表一个属性字段）进行零均值化，即减去这一行的均值
3. 求出协方差矩阵
4. 求出协方差矩阵的特征值及对应的特征向量
5. 将特征向量按对应特征值大小从上到下按行排列成矩阵，取前 k 行组成矩阵 P
6. $Y=PX$ 即为降维到 k 维后的数据

PCA计算实例

示例：以X为例，用PCA方法将上文提到的二维数据数据降到一维。

$$X = \begin{pmatrix} -1 & -1 & 0 & 2 & 0 \\ -2 & 0 & 0 & 1 & 1 \end{pmatrix}$$

- ① 因为X矩阵的每行均值已经是零均值，所以不需要去平均值
- ② 直接求其协方差矩阵

$$C = \frac{1}{5} \begin{pmatrix} -1 & -1 & 0 & 2 & 0 \\ -2 & 0 & 0 & 1 & 1 \end{pmatrix} \begin{pmatrix} -1 & -2 \\ -1 & 0 \\ 0 & 0 \\ 2 & 1 \\ 0 & 1 \end{pmatrix} = \begin{pmatrix} \frac{6}{5} & \frac{4}{5} \\ \frac{4}{5} & \frac{6}{5} \end{pmatrix}$$

PCA计算实例

③ 然后求协方差矩阵的特征值和特征向量。求解后特征值为：

$$\lambda_1 = 2, \lambda_2 = 2/5$$

- ✓ 其对应的特征向量分别是： $c_1 \begin{pmatrix} 1 \\ 1 \end{pmatrix}$, $c_2 \begin{pmatrix} -1 \\ 1 \end{pmatrix}$
- ✓ 特征向量分别是一个通解， c_1 和 c_2 可取任意实数。那么标准化后的特

征向量为： $\begin{pmatrix} \frac{1}{\sqrt{2}} \\ \frac{1}{\sqrt{2}} \end{pmatrix}$, $\begin{pmatrix} -\frac{1}{\sqrt{2}} \\ \frac{1}{\sqrt{2}} \end{pmatrix}$

PCA计算实例

④ 因此矩阵P为：

$$P = \begin{pmatrix} \frac{1}{\sqrt{2}} & \frac{1}{\sqrt{2}} \\ -\frac{1}{\sqrt{2}} & \frac{1}{\sqrt{2}} \end{pmatrix}$$

✓ 可以验证协方差矩阵C的对角化：


$$PCP^T = \begin{pmatrix} \frac{1}{\sqrt{2}} & \frac{1}{\sqrt{2}} \\ -\frac{1}{\sqrt{2}} & \frac{1}{\sqrt{2}} \end{pmatrix} \begin{pmatrix} \frac{6}{5} & \frac{4}{5} \\ \frac{4}{5} & \frac{6}{5} \end{pmatrix} \begin{pmatrix} \frac{1}{\sqrt{2}} & -\frac{1}{\sqrt{2}} \\ \frac{1}{\sqrt{2}} & \frac{1}{\sqrt{2}} \end{pmatrix} = \begin{pmatrix} 2 & 0 \\ 0 & \frac{2}{5} \end{pmatrix}$$

PCA计算实例

⑤ 最后用P的第一行乘以数据矩阵X，就得到了降维后的表示：

$$Y = \begin{pmatrix} \frac{1}{\sqrt{2}} & \frac{1}{\sqrt{2}} \end{pmatrix} \begin{pmatrix} -1 & -1 & 0 & 2 & 0 \\ -2 & 0 & 0 & 1 & 1 \end{pmatrix} = \begin{pmatrix} -\frac{3}{\sqrt{2}} & -\frac{1}{\sqrt{2}} & 0 & \frac{3}{\sqrt{2}} & \frac{1}{\sqrt{2}} \end{pmatrix}$$

□ 降维投影结果如下图：



主成分分析

主成分分析(Principal Component Analysis, 简称PCA)

- 对于正交属性空间中的样本点，如何用一个超平面对所有样本进行恰当的表达？
- 容易想到，若存在这样的超平面，那么它大概应具有这样的性质：
 - 最近重构性：样本点到这个超平面的距离都足够近；
 - 最大可分性：样本点在这个超平面上的投影能尽可能分开。
- 基于最近重构性和最大可分性，能分别得到主成分分析的两种等价推导。

主成分分析

最近重构性

- 对样本进行中心化, $\sum_i x_i = 0$, 再假定投影变换后得到的新坐标系为 $\{w_1 \ w_2 \ \dots \ w_d\}$, 其中 w_i 是标准正交基向量,

$$\|w_i\|^2 = 1, w_i^T w_j = 0 (i \neq j)$$

- 若丢弃新坐标系中的部分坐标, 即将维度降低到 $d' < d$, 则样本点在低维坐标系中的投影是 $z_i = (z_{i1}, z_{i2}, \dots, z_{id'})$, $z_{ij} = w_j^T x_i$ 是 x_i 在低维坐标下第 j 维的坐标, 若基于 z_i 来重构 x_i , 则会得到

$$\hat{x}_i = \sum_{j=1}^{d'} z_{ij} w_j$$

主成分分析

最近重构性

□ 考虑整个训练集，原样本点 $\mathbf{x}_i$ 与基于投影重构的样本点 $\hat{\mathbf{x}}_i$ 之间的距离为

$$\sum_{i=1}^m \left\| \sum_{j=1}^{d'} z_{ij} \mathbf{w}_j - \mathbf{x}_i \right\|_2^2 = \sum_{i=1}^m \mathbf{z}_i^T \mathbf{z}_i - 2 \sum_{i=1}^m \mathbf{z}_i^T \mathbf{W}^T \mathbf{x}_i + \text{const}$$
$$\propto -\text{tr} \left(\mathbf{W}^T \left(\sum_{i=1}^m \mathbf{x}_i \mathbf{x}_i^T \right) \mathbf{W} \right).$$

□ 根据最近重构性应最小化上式。考虑到 $\mathbf{w}_j$ 是标准正交基， $\sum_i \mathbf{x}_i \mathbf{x}_i^T$

是协方差矩阵，有 $\min_W -\text{tr}(\mathbf{W}^T \mathbf{X} \mathbf{X}^T \mathbf{W})$
s.t. $\mathbf{W}^T \mathbf{W} = \mathbf{I}$

这就是主成分分析的优化目标。


主成分分析

最大可分性

□ 样本点 x_i 在新空间中超平面上的投影是 $W^T x_i$ ，若所有样本点的投影能尽可能分开，则应该使得投影后样本点的方差最大化。若投影后样本点的方差是 $\sum_i W^T x_i x_i^T W$ ，于是优化目标可写为

$$\begin{aligned} \max_W & \text{tr}(W^T X X^T W) \\ \text{s.t. } & W^T W = I \end{aligned}$$

显然与 $\min_W -\text{tr}(W^T X X^T W)$ 等价。

$$\text{s.t. } W^T W = I$$


主成分分析

PCA的求解

$$\begin{aligned} \max_{\mathbf{W}} \quad & \text{tr}(\mathbf{W}^T \mathbf{X} \mathbf{X}^T \mathbf{W}) \\ \text{s.t.} \quad & \mathbf{W}^T \mathbf{W} = \mathbf{I}. \end{aligned}$$

$$\begin{aligned} \min_{\mathbf{W}} \quad & -\text{tr}(\mathbf{W}^T \mathbf{X} \mathbf{X}^T \mathbf{W}) \\ \text{s.t.} \quad & \mathbf{W}^T \mathbf{W} = \mathbf{I}. \end{aligned}$$

□ 对优化式使用拉格朗日乘子法可得

$$\mathbf{X} \mathbf{X}^T \mathbf{W} = \lambda \mathbf{W}.$$

只需对协方差矩阵 $\mathbf{X} \mathbf{X}^T$ 进行特征值分解，并将求得的特征值排序： $\lambda_1 \geq \lambda_2 \geq \dots \geq \lambda_d$ ，再取前 d' 个特征值对应的特征向量构成 $\mathbf{W} = (\mathbf{w}_1, \mathbf{w}_2, \dots, \mathbf{w}_{d'})$ ，这就是主成分分析的解。

主成分分析

PCA算法

输入：样本集 $D = \{\mathbf{x}_1, \mathbf{x}_2, \dots, \mathbf{x}_m\}$;

低维空间维数 d' .

过程：

1: 对所有样本进行中心化: $\mathbf{x}_i \leftarrow \mathbf{x}_i - \frac{1}{m} \sum_{i=1}^m \mathbf{x}_i$;

2: 计算样本的协方差矩阵 $\mathbf{X}\mathbf{X}^T$;

3: 对协方差矩阵 $\mathbf{X}\mathbf{X}^T$ 做特征值分解;

4: 取最大的 d' 个特征值所对应的特征向量 $\mathbf{w}_1, \mathbf{w}_2, \dots, \mathbf{w}_{d'}$.

输出：投影矩阵 $\mathbf{W} = (\mathbf{w}_1, \mathbf{w}_2, \dots, \mathbf{w}_{d'})$.

图 10.5 PCA 算法

主成分分析

- 降维后低维空间的维数 d' 通常是由用户事先指定，或通过在不同 d' 值的低维空间中对 k 近邻分类器（或其它开销较小的学习器）进行交叉验证来选取较好的 d' 值。对PCA，还可从重构的角度设置一个重构阈值，例如 $t = 95\%$ ，然后选取使下式成立的最小 d' 值：

$$\frac{\sum_{i=1}^{d'} \lambda_i}{\sum_{i=1}^d \lambda_i} \geq t.$$

- PCA仅需保留 $\mathbf{W}$ 与样本的均值向量即可通过简单的向量减法和矩阵-向量乘法将新样本投影至低维空间中。
- 降维虽然会导致信息的损失，但一方面舍弃这些信息后能使得样本的采样密度增大，另一方面，当数据受到噪声影响时，最小的特征值所对应的特征向量往往与噪声有关，舍弃可以起到去噪效果。

核化线性降维

- 线性降维方法假设从高维空间到低维空间的函数映射是线性的，然而，在不少现实任务中，可能需要非线性映射才能找到恰当的低维嵌入：




图 10.6 三维空间中观察到的 3000 个样本点，是从本真二维空间中矩形区域采样后以 S 形曲面嵌入，此情形下线性降维会丢失低维结构。图中数据点的染色显示出低维空间的结构。

核化线性降维

核化主成分分析 (Kernelized PCA, 简称KPCA)

▣ 非线性降维的一种常用方法，是基于核技巧对线性降维方法进行“核化” (kernelized)。

▣ 假定我们将在高维特征空间中把数据投影到由 $\mathbf{W}$ 确定的超平面上，即PCA欲求解

▣ 其中 $\mathbf{z}_i$ 是样本点 $\mathbf{x}_i$ 在高维特征空间中的像。令 $\alpha_i = \frac{1}{\lambda} \mathbf{z}_i^T \mathbf{W}$,

$$\mathbf{W} = \frac{1}{\lambda} \left(\sum_{i=1}^m \mathbf{z}_i \mathbf{z}_i^T \right) \mathbf{W} = \sum_{i=1}^m \mathbf{z}_i \frac{\mathbf{z}_i^T \mathbf{W}}{\lambda} = \sum_{i=1}^m \mathbf{z}_i \alpha_i.$$

核化线性降维

核化主成分分析 (Kernelized PCA, 简称KPCA)

- 假定 $\mathbf{z}_i$ 是由原始属性空间中的样本点 $\mathbf{x}_i$ 通过映射 ϕ 产生, 即

$$\mathbf{z}_i = \phi(\mathbf{x}_i), i = 1, 2, \dots, m.$$

$$\mathbf{W} = \sum_{i=1}^m \mathbf{z}_i \alpha_i$$

- 若 ϕ 能被显式表达出来, 则通过它将样本映射至高维空间, 再在特征空间中实施**PCA**即可, 即有

$$\left(\sum_{i=1}^m \phi(\mathbf{x}_i) \phi(\mathbf{x}_i)^T \right) \mathbf{W} = \lambda \mathbf{W}.$$

并且

$$\mathbf{W} = \sum_{i=1}^m \phi(\mathbf{x}_i) \alpha_i.$$

核化线性降维

核化主成分分析 (Kernelized PCA, 简称KPCA)

- 一般情形下，我们不清楚 ϕ 的具体形式，于是引入核函数

$$\kappa(\mathbf{x}_i, \mathbf{x}_j) = \phi(\mathbf{x}_i)^T \phi(\mathbf{x}_j).$$

- 又由 $W = \sum_{i=1}^m \phi(x_i) \alpha_i$ ，代入优化式 $(\sum_{i=1}^m \phi(x_i) \phi(x_i)^T)W = \lambda W$ ，有

$$\mathbf{K} \mathbf{A} = \lambda \mathbf{A}.$$

其中 $\mathbf{K}$ 为 κ 对应的核矩阵， $(K)_{ij} = \kappa(x_i, x_j)$, $\mathbf{A} = (\alpha_1; \alpha_2; \dots; \alpha_m)$ 。

- 上式为特征值分解问题，取 $\mathbf{K}$ 最大的 d' 个特征值对应的特征向量得到解。

核化线性降维

核化主成分分析 (Kernelized PCA, 简称KPCA)

□ 对新样本 $\mathbf{x}$, 其投影后的第 j ($j = 1, 2, \dots, d'$)维坐标为

$$\begin{aligned} z_j &= \mathbf{w}_j^T \phi(\mathbf{x}) = \sum_{i=1}^m \alpha_i^j \phi(\mathbf{x}_i)^T \phi(\mathbf{x}) \\ &= \sum_{i=1}^m \alpha_i^j \kappa(\mathbf{x}_i, \mathbf{x}). \end{aligned}$$

其中 α_i 已经过规范化, α_i^j 是 α_i 的第 j 个分量。由该式可知, 为获得投影后的坐标, KPCA需对所有样本求和, 因此它的计算开销较大。

PCA总结

- 总体来看，PCA 是一种经典且有效的线性降维方法。它通过保留方差最大的几个方向来提取数据中的主要信息，并在一定程度上减少冗余和噪声。
- 不过，由于 PCA 本质上是线性方法，因此对复杂的非线性结构刻画能力有限，这时通常需要考虑核方法或流形学习方法。

大纲


- k近邻学习
- 多维缩放
- 主成分分析
- 流形学习
- 度量学习

流形学习

- 在很多应用中，数据的维数会很高。以图像数据为例，要识别32x32的手写数字图像，如果将像素按行或者列拼接起来形成向量，这个向量的维数是1024。特征向量维数越高，机器学习算法的精度反而会降低。
- 人所能直观看到和理解的空间最多是3维的，为了数据的可视化，也需要将数据投影到低维空间中，因此就需要有数据降维这种算法来完成此任务。

流形学习


例如，下图是将0-9这10个手写数字投影到3维空间中后的结果。从图中可以清晰的看到这些手写数字在3维空间中的分布，每一个类一般聚集在某一区域内。例如7位于空间的左上角，而6则位于右下角。



流形学习

- 流形 (manifold) 是几何中的一个概念，它是高维空间中的几何结构，即空间中的点构成的集合。可以简单的将流形理解成二维空间的曲线，三维空间的曲面在更高维空间的推广。下图是三维空间中的一个流形，这是一个卷曲面：
- 2维空间中的曲线，3维空间中的曲线可以看做是2维和3维空间中的1维流形，因为曲线是1维的。而3维空间中的曲面可以看做是2维的流形，因为曲面是2维的。 **n 维空间中的 m 维流形就是具有 m 维几何形状的一个子集，在这里 m 小于 n 。**

流形学习



流形学习

- 很多应用问题的数据在高维空间中的分布具有某种几何形状，即**集中在某个低维的流形附近**。对于前面所说的32x32的手写数字图像，数字7的图像在1024维空间中应该聚集在某一个形状的几何体周围（如带状区域，球面），其他的类别也是如此。
- 流形学习（manifold learning）认为，虽然数据样本位于高维空间中，但它们往往并不是均匀分布在整个高维空间里，而是集中在某个低维流形附近。因此，如果能够恢复这个低维流形结构，就有可能实现更合理的降维。
- 假设有一个N维空间中的流形M，即M为N维欧氏空间的一个真子集： $M \subset \mathbb{R}^N$

流形学习降维算法要实现的是如下映射： $M \rightarrow \mathbb{R}^n$

其中 $n \ll N$ 。即将**N维空间中流形M上的点映射为n维空间中的点**。

流形学习

- 流形学习(manifold learning)是一类借鉴了拓扑流形概念的降维方法。“流形”是在局部与欧氏空间同胚的空间，换言之，它在局部具有欧氏空间的性质，能用欧氏距离来进行距离计算。
- 若低维流形嵌入到高维空间中，则数据样本在高维空间的分布虽然看上去非常复杂，但在局部上仍具有欧氏空间的性质，因此，可以容易地在局部建立降维映射关系，然后再设法将局部映射关系推广到全局。
- 当维数被降至二维或三维时，能对数据进行可视化展示，因此流形学习也可被用于可视化。

流形学习

等度量映射(Isometric Mapping, Isomap)

- 等距映射 (Isomap) 使用了微分几何中测地线的思想，它希望数据在向低维空间映射之后能够保持流形上的测地线距离。直观来看，就是将数据投影到低维空间之前，保持数据点之间的相对远近关系。
- 测地线是微分几何中的一个概念，源自于大地测量学，是地球上任意两点之间在球面上的最短路径。在非线性流形上，样本之间真正有意义的距离往往不是欧氏距离，而是沿流形表面的测地线距离。因此，Isomap 通过保持测地线距离来实现降维。

流形学习



流形学习

- 等距映射算法计算任意两个样本之间的测地距离，然后根据这个距离构造距离矩阵。最后通过距离矩阵求解优化问题完成数据的降维，降维之后的数据保留了原始数据点之间的距离信息。
- 在这里测地线距离通过图构造，是图的两个节点之间的最短距离。算法的第一步构造样本集的邻居图，假设有 N 个样本，则邻居图有 N 个节点。邻居图的节点 i 和 j 之间边的权重为它们之间的距离 w_{ij} 。
- 第二步计算图中任意两点之间的最短路径长度，可以通过经典的Dijkstra算法实现。
- 假设最短路径长度为 $d_G(i, j)$ ，由它构造如下矩阵： $D_G = \{d_G(i, j)\}$
- 其元素是所有节点对之间的最短路径长度。
- 算法的第三步根据矩阵 D_G 构造 d 维投影，这通过求解如下最优化问题实现：

$$\min_y \sum_{i=1}^N \sum_{j=1}^N \left(d_G(i, j) - \|y_i - y_j\| \right)^2$$

流形学习

- 优化的目标: 降维之前任意两点间的最短距离, 与降维之后这两点间的最短距离, 要尽可能接近。这个问题的解 y_i 即为降维之后的向量。这个目标函数的意义是向量降维之后任意两点之间的距离要尽量的接近在原始空间中这两点之间的最短路径长度, 因此可以认为降维尽量保留了数据点之间的测地距离信息。
- 可以形象的把这个过程理解成将3D的地球仪投影到2D的平面地图上, 投影之前, 美国离中国的距离远, 泰国离中国的距离近, 投影之后要保持这种距离关系:


流形学习



流形学习

等度量映射(Isometric Mapping, Isomap)

- 低维流形嵌入到高维空间之后，直接在高维空间中计算直线距离具有误导性，因为高维空间中的直线距离在低维嵌入流形上不可达。而低维嵌入流形上两点间的本真距离是“测地线”(geodesic)距离。




(a) 测地线距离与高维直线距离

流形学习

等度量映射(Isometric Mapping, Isomap)

- 测地线距离的计算：利用流形在局部上与欧氏空间同胚这个性质，对每个点基于欧氏距离找出其近邻点，然后就能建立一个近邻连接图。
- 于是，计算两点之间测地线距离的问题就转变为计算近邻连接图上两点之间的最短路径问题。
- 最短路径的计算可通过Dijkstra算法或Floyd算法实现。



(b) 测地线距离与近邻距离

流形学习

等度量映射(Isometric Mapping, Isomap)

输入: 样本集 $D = \{\mathbf{x}_1, \mathbf{x}_2, \dots, \mathbf{x}_m\}$;

近邻参数 k ;

低维空间维数 d' .

过程:

1: **for** $i = 1, 2, \dots, m$ **do**

2: 确定 $\mathbf{x}_i$ 的 k 近邻;

3: $\mathbf{x}_i$ 与 k 近邻点之间的距离设置为欧氏距离, 与其他点的距离设置为无穷大;

4: **end for**

5: 调用最短路径算法计算任意两样本点之间的距离 $\text{dist}(\mathbf{x}_i, \mathbf{x}_j)$;

6: 将 $\text{dist}(\mathbf{x}_i, \mathbf{x}_j)$ 作为 MDS 算法的输入;

7: **return** MDS 算法的输出

输出: 样本集 D 在低维空间的投影 $Z = \{\mathbf{z}_1, \mathbf{z}_2, \dots, \mathbf{z}_m\}$.

图 10.8 Isomap 算法

流形学习


局部线性嵌入 (Locally Linear Embedding, LLE)

- 局部线性嵌入的**核心思想**是每个样本点都可以由与它相邻的多个点的线性组合（体现了局部线性）来近似重构，这相当于用分段的线性面片近似代替复杂的几何形状，样本投影到低维空间之后要保持这种线性重构关系，即有相同的重构系数。
- 假设数据集由 n 个 D 维向量 x_i 组成，它们分布在 D 维空间中的一个流形附近。每个数据点和它的邻居位于或者接近于流形的一个局部线性片段（平面，体现了线性，**类似于微积分中的以直代曲的思想**）上，即可以用邻居点的线性组合来重构，组合系数刻画了局部面片的几何特性：

$$x_i \approx \sum_j w_{ij} x_j$$

流形学习

- 局部线性嵌入试图保持邻域内的线性关系，并使得该线性关系在降维后的空间中继续保持。权重 w_{ij} 为第j个数据点对第i个点的组合权重，这些点的线性组合被用来近似重构数据点i。



$$\mathbf{x}_i = w_{ij}\mathbf{x}_j + w_{ik}\mathbf{x}_k + w_{il}\mathbf{x}_l$$

流形学习

□ LLE先为每个样本 $\mathbf{x}_i$ 找到其近邻下标集合 Q_i ，然后计算出基于 Q_i 的中的样本点对 $\mathbf{x}_i$ 进行线性重构的系数 $\mathbf{w}_i$ ：

权重系数通过最小化重构误差确定：

$$\min_{\mathbf{w}_1, \mathbf{w}_2, \dots, \mathbf{w}_m} \sum_{i=1}^m \left\| \mathbf{x}_i - \sum_{j \in Q_i} w_{ij} \mathbf{x}_j \right\|_2^2$$

s.t. $\sum_{j \in Q_i} w_{ij} = 1$, 带约束优化问题

其中 $\mathbf{x}_i$ 和 $\mathbf{x}_j$ 均为已知，令 $Q = \sum_i \left\| \mathbf{x}_i - \sum_j w_{(ij)} \mathbf{x}_j \right\|_2^2$ ， w_{ij} 有闭式解

$$w_{ij} = \frac{\sum_{k \in Q_i} C_{jk}^{-1}}{\sum_{l, s \in Q_i} C_{ls}^{-1}}.$$

流形学习

可以证明权重值对平移、旋转、缩放等几何变换具有不变性。

□ LLE在低维空间中保持 $\mathbf{w}_i$ 不变，于是 $\mathbf{x}_i$ 对应的低维空间坐标 $\mathbf{z}_i$ 可通过下式求解：

$$\min_{\mathbf{w}_1, \mathbf{w}_2, \dots, \mathbf{w}_m} \sum_{i=1}^m \left\| \mathbf{z}_i - \sum_{j \in Q_i} w_{ij} \mathbf{z}_j \right\|_2^2$$


□ 令 $\mathbf{Z} = (\mathbf{z}_1, \mathbf{z}_2, \dots, \mathbf{z}_m) \in \mathbb{R}^{d' \times m}$, $(W)_{ij} = w_{ij}$,

$$\mathbf{M} = (\mathbf{I} - \mathbf{W})^T (\mathbf{I} - \mathbf{W})$$

□ 则优化式可重写为右式，并通过特征值分解求解。


$$\begin{aligned} \min_{\mathbf{Z}} \quad & \text{tr}(\mathbf{Z} \mathbf{M} \mathbf{Z}^T) \\ \text{s.t.} \quad & \mathbf{Z} \mathbf{Z}^T = \mathbf{I}. \end{aligned}$$

流形学习



流形学习

下图为用LLE算法将手写数字图像投影到3维空间后的结果



流形学习

输入: 样本集 $D = \{\mathbf{x}_1, \mathbf{x}_2, \dots, \mathbf{x}_m\}$;

近邻参数 k ;

低维空间维数 d' .

过程:

1: **for** $i = 1, 2, \dots, m$ **do**

2: 确定 $\mathbf{x}_i$ 的 k 近邻;

3: 从式(10.27)求得 $w_{ij}, j \in Q_i$;

4: 对于 $j \notin Q_i$, 令 $w_{ij} = 0$;

5: **end for**

6: 从式(10.30)得到 $\mathbf{M}$;

7: 对 $\mathbf{M}$ 进行特征值分解;

8: **return** $\mathbf{M}$ 的最小 d' 个特征值对应的特征向量

输出: 样本集 D 在低维空间的投影 $Z = \{\mathbf{z}_1, \mathbf{z}_2, \dots, \mathbf{z}_m\}$.

图 10.10 LLE 算法

大纲

- k近邻学习
- 多维缩放
- 主成分分析
- 流形学习
- 度量学习

度量学习

研究动机

- 在机器学习中，对高维数据进行降维的主要目的是希望找到一个合适的低维空间，在此空间中进行学习能比原始空间性能更好。
- 既然很多学习任务最终都依赖于样本之间的相似性或距离，那么与其先改变表示空间，不如直接学习一个更符合任务需求的距离函数。这就是度量学习的基本出发点。

度量学习

- 欲对距离度量进行学习，必须有一个便于学习的距离度量表达形式。对两个 d 维样本 $\mathbf{x}_i$ 和 $\mathbf{x}_j$ ，它们之间的平方欧氏距离可写为

$$\text{dist}_{\text{ed}}^2(\mathbf{x}_i, \mathbf{x}_j) = \|\mathbf{x}_i - \mathbf{x}_j\|_2^2 = \text{dist}_{ij,1}^2 + \text{dist}_{ij,2}^2 + \cdots + \text{dist}_{ij,d}^2,$$

- 其中 $\text{dist}_{ij,k}$ 表示 $\mathbf{x}_i$ 与 $\mathbf{x}_j$ 在第 k 维上的距离。若假定不同属性的重要性不同，则可引入属性权重 $\mathbf{w}$ ，得到

$$\begin{aligned}\text{dist}_{\text{wed}}^2(\mathbf{x}_i, \mathbf{x}_j) &= \|\mathbf{x}_i - \mathbf{x}_j\|_2^2 = w_1 \cdot \text{dist}_{ij,1}^2 + w_2 \cdot \text{dist}_{ij,2}^2 + \cdots + w_d \cdot \text{dist}_{ij,d}^2 \\ &= (\mathbf{x}_i - \mathbf{x}_j)^T \mathbf{W} (\mathbf{x}_i - \mathbf{x}_j),\end{aligned}$$

- 其中 $w_i \geq 0$, $\mathbf{W} = \text{diag}(\mathbf{w})$ 是一个对角矩阵, $(\mathbf{W})_{ii} = w_i$, 可通过学习确定。

度量学习

- $\mathbf{W}$ 的非对角元素均为零，这意味着坐标轴是正交的，即属性之间无关；但现实问题中往往不是这样，例如考虑西瓜的“重量”和“体积”这两个属性，它们显然是正相关的，其对应的坐标轴不再正交。为此将 $\mathbf{W}$ 替换为一个普通的半正定对称矩阵 $\mathbf{M}$ ，于是就得到了马氏距离(Mahalanobis distance)。

$$\text{dist}_{\text{mah}}^2(\mathbf{x}_i, \mathbf{x}_j) = (\mathbf{x}_i - \mathbf{x}_j)^T \mathbf{W} (\mathbf{x}_i - \mathbf{x}_j) = \|\mathbf{x}_i - \mathbf{x}_j\|_{\mathbf{M}}^2$$

其中 $\mathbf{M}$ 亦称“度量矩阵”，而度量学习则是对 $\mathbf{M}$ 进行学习。注意到为了保持距离非负且对称， $\mathbf{M}$ 必须是（半）正定对称矩阵，即必有正交基 $\mathbf{P}$ 使得 $\mathbf{M}$ 能写为 $\mathbf{M} = \mathbf{P}\mathbf{P}^T$ 。

- 对 $\mathbf{M}$ 进行学习当然要设置一个目标。假定我们是希望提高近邻分类器的性能，则可将 $\mathbf{M}$ 直接嵌入到近邻分类器的评价指标中去，通过优化该性能指标相应地求得 $\mathbf{M}$ 。

近邻成分分析(Neighbourhood Component Analysis, NCA)

□ 近邻成分分析在进行判别时通常使用多数投票法，邻域中的每个样本投1票，邻域外的样本投0票。

不妨将其替换为概率投票法。对于任意样本 $\mathbf{x}_j$ ，它对 $\mathbf{x}_i$ 分类结果影响的概率为 $p_{ij} = \frac{\exp(-\|\mathbf{x}_i - \mathbf{x}_j\|_M^2)}{\sum_l \exp(-\|\mathbf{x}_i - \mathbf{x}_l\|_M^2)}$

□ 当 $i = j$ 时， p_{ij} 最大。显然， $\mathbf{x}_j$ 对 $\mathbf{x}_i$ 的影响随着它们之间距离的增大而减小。若以留一法(LOO)正确率的最大化为目标，则可计算 $\mathbf{x}_i$ 的留一法正确率，即它被自身之外的所有样本正确分类的概率为 p_i

$$= \sum_{j \in \Omega_i} p_{ij}$$

其中 Ω_i 表示与 $\mathbf{x}_i$ 属于相同类别的样本的下标集合。

近邻成分分析(Neighbourhood Component Analysis, NCA)

□ 整个样本集上的留一法正确率为

$$\sum_{i=1}^m p_i = \sum_{i=1}^m \sum_{j \in \Omega_i} p_{ij}.$$

□ 由 $p_{ij} = \frac{\exp(-\|x_i - x_j\|_M^2)}{\sum_l \exp(-\|x_i - x_l\|_M^2)}$ 和 $M = PP^T$, 则NCA的优化目标为

$$\min_{\mathbf{P}} \quad 1 - \sum_{i=1}^m \sum_{j \in \Omega_i} \frac{\exp(-\|\mathbf{P}^T \mathbf{x}_i - \mathbf{P}^T \mathbf{x}_j\|_2^2)}{\sum_l \exp(-\|\mathbf{P}^T \mathbf{x}_i - \mathbf{P}^T \mathbf{x}_l\|_2^2)}.$$

求解即可得到最大化近邻分类器LOO正确率的距离度量矩阵 M 。

度量学习

- 实际上，不仅能将错误率这样的监督学习目标作为度量学习的优化目标，还能在度量学习中引入领域知识。
- 若已知某些样本相似、某些样本不相似，则可定义“必连” (must-link) 约束集合 $\mathcal{C}$ 与“勿连” (cannot-link) 约束集合 $\mathcal{M}$ ：

$(x_i, x_j) \in \mathcal{C}$ 表示 x_i 与 x_j 相似， $(x_i, x_j) \in \mathcal{M}$ 表示 x_i 与 x_j 不相似。显然，我们希望相似的样本之间距离较小，不相似的样本之间距离较大，于是可通过求解下面这个凸优化问题获得适当的度量矩阵 M ：

$$\begin{aligned} \min_M \quad & \sum_{(x_i, x_j) \in \mathcal{C}} \|x_i - x_j\|_M^2 \\ \text{s. t.} \quad & \sum_{(x_i, x_j) \in \mathcal{M}} \|x_i - x_j\|_M^2 \geq 1, \quad M \succeq 0 \end{aligned}$$

- 其中约束 $M \succeq 0$ 表明 M 必须是半正定的。上式要求在不相似样本间的距离不小于1的前提下，使相似样本间的距离尽可能小。

度量学习

- 不同的度量学习方法针对不同目标获得“好”的半正定对称距离度量矩阵 M ，若 M 是一个低秩矩阵，则通过对 M 进行特征值分解，总能找到一组正交基，其正交基数目为矩阵 M 的秩 $rank(M)$ ，小于原属性数 d 。于是，度量学习学得的结果可衍生出一个降维矩阵 $P \in \mathbb{R}^{d \times rank(M)}$ ，能用于降维之目的。



重庆大学
CHONGQING UNIVERSITY

THANKS
祝学习快乐!